Atelier 2 : Notion de la donnée
(Prétraitement et préparation des données)

Pour que les algorithmes de Machine Learning fonctionnent, il est nécessaire de convertir les données brutes en un ensemble de données propres. Des données inadaptées ou mal gérées entraîneront de mauvais résultats du projet, quelle que soit l'approche de modélisation. Dans cet atelier, nous apprendrons comment prétraiter et préparer les données afin qu'elles puissent être interprétées par l'algorithme de Machine Learning. Vous utiliserez les APIs **Pandas** (`pandas`) pour charger des données et NumPy (`numpy`) pour préparer les données pour la phase d'apprentissage.

1. L'ensemble de données

Pour cet objectif, nous utiliserons un ensemble de données comprenant des données physiologiques anonymisées collectées auprès de patients gravement malades « *eICU Collaborative Research Database* ». Pour plus de simplicité, nous travaillerons avec des fichiers CSV pré-préparés comprenant des données extraites d'une version de démonstration de l'ensemble de données.

- Le lien de dataset (fichiers CSV) : https://physionet.org/content/eicu-crd-demo/2.0.1/
- Pour plus d'information sur *eICU Collaborative Research Databas :* *https://eicu-crd.mit.edu/about/eicu/*

2. Etapes de prétraitement des données

1. Chargez des données dans Pandas.
2. Supprimez les colonnes qui ne sont pas utiles.
3. Supprimez les lignes avec des valeurs manquantes.
4. Prenez soin des données manquantes.
5. Convertissez le bloc de données en NumPy.

Travail à faire :

1. Dans un premier temps, nous suivrons le tutoriel dans ce lien https://builtin.com/machine-learning/how-to-preprocess-data-python, étape par étape, pour prétraiter et préparer l'ensemble de données *Titanic*.
2. Appliquer ces techniques de prétraitement sur l'ensemble de données *eICU Collaborative Research Database* afin de le nettoyer et de le préparer pour la phase d'apprentissage.